

Regroupement géométrique d'images d'archives de Flickr Commons

Pipeline inspirée de la photogrammétrie

Amine ZOZOU | SC-BA6

Projet de Recherche de Bachelor

DHLAB × Flickr Foundation | Superviseur : Frédéric Kaplan



Flickr Commons : un patrimoine visuel à grande échelle

- Programme lancé en 2008 : des bibliothèques, musées et archives y publient leurs collections sous la mention « ***no known copyright restrictions*** ».
- Des millions de photographies d'archives diffusées librement par des institutions du monde entier
- Flickr Commons est un dataset massif et hétérogène :
 - Forte variabilité visuelle
 - Pas de labels fiables
 - Mélange : photos, peintures, scans
- Le volume considérable rend toute organisation manuelle impossible → **besoin d'outils automatiques.**

Une même scène, sous des formes multiples



Carte postale colorisée
Support imprimé, couleurs peintes,
annotation manuscrite



Photographie, vue d'ensemble
Couleurs naturelles, prise de vue
oblique à distance



Photographie, gros plan
Contre-plongée serrée sur la tour

Comment regrouper automatiquement les images représentant la même scène ?

Deux approches naïves, deux échecs

On veut prouver que deux images montrent la même scène physique



Comparaison pixel à pixel

Échoue dès le moindre **recadrage, changement de contraste ou de numérisation**. Deux scans du même tirage ne partagent presque aucun pixel identique.



Similarité sémantique seule

Sur-regroupe : deux cathédrales gothiques différentes ont des vecteurs proches, alors qu'il s'agit de scènes physiques distinctes.

Solution : Vérification géométrique (idée centrale de la pipeline)


Définition formelle du problème



Un groupe peut contenir une seule image (singleton) : une scène sans duplicata dans la collection.

Le pipeline en quatre étapes

Rappel sémantique bon marché → précision géométrique coûteuse → regroupement par graphe



Le filtre CLIP évite la comparaison géométrique de toutes les paires ($\approx N^2/2$), trop coûteuse à grande échelle.

1) Candidats, récupération sémantique (CLIP)

- Pour chaque image, on ne retient que les k voisins les plus proches comme **paires candidates** à vérifier ensuite.
- Chaque image est encodée par **CLIP ViT-B/32** en un vecteur sémantique (embeddings pré-calculés).
- Déjà calculé au préalable, stocké dans la database
- Sélectionne les k images les plus similaires visuellement
Conséquences : $N^2 \rightarrow N \times k$

PARAMÈTRES

$\tau = 0,75$ seuil de similarité cosinus

top-k = 10 voisins retenus par image



Itération : le modèle de récupération est passé de DINOv2 à CLIP (embeddings fournis par Ghassan).

2) Vérification géométrique, le cœur du système



1 • Points caractéristiques

SIFT + RootSIFT, avec prétraitement CLAHE pour rehausser les photos délavées.



2 • Appariement robuste

Plus proches voisins + ratio de Lowe : on ne garde que les correspondances fiables.



3 • Double RANSAC F / H

F (3 px) pour les scènes en relief, H (4 px) pour les scènes planes. ≥ 20 inliers $\rightarrow$ arête validée.

≥ 20

inliers minimum

0,75

ratio de Lowe

3 / 4 px

seuils F / H

$m = 3$

élagage des arêtes



Et LightGlue ? Un appariement appris (LightGlue) a été envisagé comme étape de confirmation, puis écarté après évaluation — voir la slide suivante.

Correspondances vérifiées autour de l'image représentante

La vue d'ensemble (image centrale du cluster) est vérifiée contre les deux autres vues — les trois forment un seul groupe.




Représentante ↔ carte postale colorisée

22 inliers

27,9 score

F modèle



Représentante ↔ gros plan de la tour

62 inliers

180,2 score

F modèle



Reliée aux deux autres vues, cette image partage le plus de structure géométrique → score de centralité maximal (is_central).

3) Graphe & sélection du représentant

1) Construction du graphe

Nœud = image · arête = paire vérifiée géométriquement.

2) Élagage & composantes

Arêtes faibles retirées ($m = 3$) ; chaque composante connexe (NetworkX) = un groupe.




is_central — le représentant du groupe

Centralité par qualité d'appariement moyenne : le nœud le plus connecté géométriquement de sa composante.

```
edge_score(u,v) = n_inliers × inlier_ratio × log(1 + n_good)
centrality(v) = moyenne des edge_score sur les voisins valides
de v
```

is_central = nœud de score moyen maximal dans le groupe

Graphe de similarité



nœud étoilé = is_central · nœud isolé = singleton

Résultats -> set pauvre ($\approx 2,2$ photos/cluster)

164

clusters au total



63

clusters éligibles (≥ 2 images)



15

produisent ≥ 1 groupe

couverture 9,5 %

15

groupes formés

34

photos regroupées

2,3

images / groupe (moy.)



La plupart des clusters éligibles ne contiennent pas de doublons → couverture basse, attendue sur un échantillon peu dense. La couverture suit la densité du jeu (jusqu'à 58 % sur un jeu plus dense) ; la justesse des groupes formés, elle, reste ≈ 92 %.

Résultats -> set dense (≈ 16 photos/cluster)

227

clusters traités



couverture 58 %

132

produisent ≥ 1 groupe



386

groupes formés

1123

photos regroupées

1,70

groupes / cluster (moy.)

≈ 16

photos / cluster



Jeu plus dense → **beaucoup plus de vrais doublons** → couverture 58 % (contre 9,5 % sur le petit jeu). Le même étage de vérification, la même précision (≈ 92 %) : seule la densité du jeu change.

Précision de l'étage de vérification


$\approx 92\%$

219 / 237 images

précision pondérée

30 groupes annotés (20 grands + 10 petits aléatoires)

Pureté par groupe (vrais / total)




Ci-dessus : 20 plus grands groupes (15 purs, 2 dégradés) · + 10 petits aléatoires : 0 erreur

Cas dégradés — trop peu de points SIFT. Sur ces clusters, le détecteur trouve trop peu de points stables → trop peu de correspondances → sous le seuil d'inliers. Limite de l'entrée (images pauvres en features), pas de la vérification.

Correct ≠ utile. Quelques groupes corrects (mur, intérieur, porte, vitraux) ont une faible valeur patrimoniale : surfaces planes peu distinctives. La précision géométrique, elle, reste $\approx 92\%$.

Couverture, densité & périmètre

Couverture selon la densité · clusters avec ≥ 1 groupe



Mon périmètre. L'entrée est une partition de clusters candidats produite en amont (clustering géographique, hors de ma contribution). Mon module : vérifier géométriquement et regrouper.



La couverture suit la densité du jeu, pas la qualité de la vérification : plus il y a de vrais doublons, plus de groupes se forment. La précision des groupes (≈ 92 %) reste, elle, indépendante de la densité.

Bases légèrement différentes (couverture sur éligibles / sur clusters traités) ; tendance néanmoins nette.

En conclusion ...

Un pipeline qui combine **rappel sémantique (CLIP)** et **preuve géométrique** pour regrouper de façon fiable les images d'une même scène dans les archives de Flickr Commons.



La géométrie fait la différence — elle transforme « ça se ressemble » en « c'est la même scène ».



Deux étages = efficacité — filtre bon marché puis vérification coûteuse ciblée.



Sortie exploitable — groupes + représentant (is_central) pour naviguer les collections.

Bibliographie · sources · licence



Références principales

- Radford et al. (2021) — CLIP

Lowe (2004) — SIFT

Arandjelović & Zisserman (2012) — RootSIFT

Fischler & Bolles (1981) — RANSAC

Lindenberger et al. (2023) — LightGlue

Hartley & Zisserman — Multiple View Geometry (F, H)

Oquab et al. (2023) — DINOv2 (itération antérieure)

Sources des images

Flickr Commons — Bibliothèque de Toulouse

« *No known copyright restrictions* »

Merci ! Questions ?

Pourquoi pas LightGlue ?

LightGlue (appariement appris) testé comme étape de confirmation sur 10 clusters : **jamais meilleur que SIFT + RANSAC seul.**

Cluster (photos)	SIFT seul : arêtes → groupes	+ LightGlue : arêtes → groupes	Surcoût temps
rank01 (36)	98 → 1 groupe propre	88 → 5 fragments	×11
rank06 (10)	20 → 1 groupe propre	9 → 5 fragments	×4
rank10 (8)	16 → 1 groupe	15 → 1 groupe (idem)	×2,5



Moins d'arêtes → fragmentation. LightGlue valide moins de paires et déconnecte des groupes corrects.



Coût en temps massif. ×2 à ×430 selon le cluster, sans aucun gain de qualité.

Décision : SIFT + RANSAC seul — plus simple, plus rapide, au moins aussi juste (parcimonie). *Test exploratoire sur 10 clusters, tendance nette.*